

# Xây dựng mô hình Nhận diện Chữ viết tay Tiếng Việt sử dụng kiến trúc Transformer

Nguyễn Huyền Trang  
20020727  
QH-2020-I-CQ-R  
Khoa Điện tử Viễn thông  
ĐHCN - ĐHQGHN  
htrang.cyb@gmail.com

Lê Thị Trang  
20020726  
QH-2020-I-CQ-R  
Khoa Điện tử Viễn thông  
ĐHCN - ĐHQGHN  
lethitran.611@gmail.com

Nguyễn Thành Quốc  
20020707  
QH-2020-I-CQ-R  
Khoa Điện tử Viễn thông  
ĐHCN - ĐHQGHN  
thanhquocltqb@gmail.com

**Tóm tắt**—Báo cáo dưới đây trình bày phương pháp thực hiện xây dựng một mô hình học máy nhận diện chữ viết tay Tiếng Việt với các quy trình cơ bản gồm: làm sạch, tiền xử lý dữ liệu, huấn luyện mô hình và thử nghiệm trên bộ dữ liệu OCR. Nhóm thực hiện xây dựng mô hình học máy gồm bộ mã hóa và bộ giải mã sử dụng kiến trúc mạng Transformer để giải quyết bài toán OCR. Mục tiêu của đề tài mong muốn giải quyết được bài toán nhận dạng ký tự và âm tiết Tiếng Việt với văn bản chữ cái bị biến đổi khi viết tay.

**Từ khóa**—*machine learning, OCR, Vietnamese cursive, Transformer-based OCR, MaskOCR.*

## I. TỔNG QUAN

OCR (Optical Character Recognition - Nhận dạng ký tự quang học) là hệ thống chuyển đổi nhiều dạng văn bản đánh máy hoặc viết tay trên giấy hay hình ảnh thành dạng số hóa giúp máy tính có thể thực hiện xử lý, sửa chữa và tìm kiếm thông tin trên các tài liệu này. Một trong những hệ thống OCR đầu tiên được ra đời vào những năm 1940 và vẫn đang được nghiên cứu và phát triển mạnh mẽ cùng với sự tiến bộ của các hệ thống học máy, học sâu hiện đại. Tuy nhiên, ứng dụng OCR với văn bản viết tay Tiếng Việt vẫn còn gặp nhiều khó khăn khi xử lý ngôn ngữ có nhiều âm tiết và thanh điệu như hệ thống chữ Quốc ngữ, đặc biệt khi chúng bị biến đổi bởi ảnh chụp hay cách viết tay của mỗi người.

Một số thách thức gặp phải khi giải quyết bài toán nhận diện chữ viết tay tiếng Việt như sự phức tạp của bộ chữ Quốc ngữ với 29 ký tự (trong đó có 10 ký tự mang thanh điệu) và hệ thống từ tiếng Việt rất đa dạng về ngữ nghĩa - với một từ mang thanh điệu khác nhau có thể mang nghĩa hoàn toàn khác nhau. Tiếng Việt còn phụ thuộc rất nhiều vào ngữ cảnh, từ văn bản chính thống đến ngôn ngữ địa phương hay thuật ngữ chuyên ngành. Đặc biệt trong thực tế, đầu vào cho hệ thống là hình ảnh có chất lượng kém như tài liệu cũ, ảnh chụp từ điện thoại di động; điều này đặt ra thách thức cho việc lọc nhiễu và xử lý biến dạng.

Nhận dạng văn bản viết tay là một vấn đề nghiên cứu lâu đời nhằm hỗ trợ quá trình chuyển đổi số ở các tài liệu truyền thống. Các phương pháp OCR hiện tại thường được xây dựng dựa trên việc trích xuất đặc trưng hình ảnh bằng các kiến trúc mạng CNN và kết hợp với họ mạng RNN để tạo văn bản ở mức ký tự. Thêm vào đó, một mô hình ngôn ngữ khác cũng thường được sử dụng ở các bước hậu xử lý nhằm tăng độ chính xác cho mô hình. Với báo cáo của nhóm, nhóm đề xuất sử dụng mô hình học máy với kiến trúc mạng Transformer để xử lý và nhận dạng chữ viết tay thông qua hai phương pháp huấn luyện bộ mã hóa – giải mã thông thường và khi sử dụng cơ chế masking.

## A. Phát biểu bài toán.

Bài toán nhận diện chữ viết tay tiếng Việt là một bài toán trong lĩnh vực thị giác máy tính mà mục tiêu chính là nhận diện và chuyển đổi các hình ảnh chứa chữ viết tay tiếng Việt thành văn bản văn bản bằng mã (textual representation). Phát biểu bài toán nhận diện chữ viết tay tiếng Việt có thể được trình bày như sau: cho một hình ảnh chứa chữ viết tay tiếng Việt, mục tiêu của bài toán là xác định văn bản chữ viết tay tiếng Việt trong hình ảnh đó.

**Đầu vào:** Hình ảnh chứa chữ viết tay tiếng Việt.


**Đầu ra:** Văn bản chữ tiếng Việt nhận diện được từ ảnh.

**Mô tả:** Bài toán nhận diện chữ viết tay tiếng Việt yêu cầu phải thực hiện một số nhiệm vụ quan trọng sau:

- Xử lý hình ảnh đầu vào: Đầu tiên, hình ảnh đầu vào cần phải được xử lý để loại bỏ nhiễu, điều chỉnh độ tương phản và kích thước, nếu cần.
- Phát hiện ký tự: Bước tiếp theo là phát hiện các ký tự trong hình ảnh, thực hiện bằng các thuật toán phát hiện đối tượng hoặc mạng nơ-ron sâu.
- Nhận diện ký tự: Sau khi các ký tự được phát hiện, xây dựng một hệ thống nhận diện ký tự xác định chữ cái cụ thể trong từng ký tự bằng mô hình học máy hoặc mạng nơ-ron sâu.
- Ghép kết quả: Cuối cùng, các ký tự được nhận diện sẽ được ghép lại để tạo thành văn bản chữ viết tay tiếng Việt hoàn chỉnh.

## B. Đề xuất phương án.

Bài toán OCR được nhóm tiếp cận theo mô hình chung như sau:



Hình 1. Mô hình tổng quát cho bài toán OCR.

**Encoder:** Bộ mã hoá trích xuất các thông tin trong ảnh, đầu ra sẽ là ma trận đặc trưng (Feature Map) chứa thông tin hình ảnh đầu vào.


**Decoder:** Bộ giải mã sẽ được thiết kế khác nhau. Bộ giải mã có nhiệm vụ giải mã đặc trưng từ bộ mã hoá thành chuỗi đầu ra.

## II. CƠ SỞ LÝ THUYẾT

### A. Kiến trúc Transformer.

Transformer là một kiến trúc học sâu được phát triển bởi Google sử dụng cơ chế multi-head attention, đề xuất lần đầu trong bài báo Attention is all you need (2017) [1]. Trong nghiên cứu này, văn bản được chuyển hóa thành dạng biểu diễn số học gọi là tokens, và mỗi token được ghi lại dưới dạng vector tìm kiếm trong bảng nhúng từ. Trong mỗi layer của kiến trúc này, mỗi token được xem xét ngữ cảnh của nó bằng cách so sánh chúng với những (unmasked) tokens khác trong phạm vi của sổ thông qua cơ chế multi-head attention; cơ chế này tăng cường tín hiệu cho các tokens chứa nhiều thông tin và giảm các token ít quan trọng. Kiến trúc Transformer có ứng dụng trong xử lý ngôn ngữ tự nhiên, thị giác máy tính, xử lý âm thanh và đa phương tiện. Nó cũng dẫn đến sự phát triển của các hệ thống được đào tạo trước, chẳng hạn như GPTs và BERT[2].

Tương tự như các mô hình dịch máy khác, kiến trúc tổng quan của mô hình transformer bao gồm hai phần là encoder và decoder. Encoder dùng để học vector biểu diễn của từ với mong muốn rằng vector này mang thông tin hoàn hảo của từ đó. Decoder thực hiện chức năng chuyển vector biểu diễn kia thành ngôn ngữ mục tiêu dịch được. Một ảnh thông qua mô hình CNN sẽ cho ra một feature maps có kích thước  $C * H * W$ . Feature maps - Bản đồ đặc trưng này sẽ trở thành đầu vào cho phần Positional Encoding trước khi truyền vào làm input cho bộ Encoder. Kiến trúc chi tiết của mạng Transformer được mô tả ở hình 2.



Hình 2. Kiến trúc mạng Transformer (nguồn).

### B. Transformer-based OCR

Trong bài báo **Transformer-based OCR with Pre-trained models (TrOCR)** [3], nhóm tác giả Microsoft đã đề xuất một phương pháp nhận dạng văn bản end-to-end với hai mô hình đều tận dụng kiến trúc mạng Transformer cho cả 2 bước mã hóa và giải mã với bộ dữ liệu được tiền huấn luyện trước, một dùng để trích xuất đặc trưng từ hình ảnh và một để

tạo văn bản ở mức từ. Mô hình TrOCR này tuy đơn giản nhưng mang lại độ hiệu quả cao và có thể được tiền huấn luyện với dữ liệu tổng hợp quy mô lớn và tinh chỉnh với các tập dữ liệu được gắn nhãn bởi con người.

#### 1) Bộ mã hóa.

Bộ mã hóa của mô hình TrOCR nhận ảnh đầu vào có kích thước  $x_{img} \in R^{3 \times H_0 \times W_0}$  và ảnh được thay đổi về kích thước cố định  $(H, W)$ . Cần thực hiện quá trình trên bởi mạng mã hóa của Transformer không thể xử lý từ ảnh đầu vào là ảnh gốc, vì vậy ảnh sẽ được duỗi ra thành các tokens để đưa vào mạng. Mạng mã hóa phân tách ảnh đầu vào thành các batch  $N = \frac{HW}{P^2}$  với kích thước patches cố định  $(P, P)$ , khi đó

chiều dài  $W$  và chiều cao  $H$  của ảnh đã được thay đổi đảm bảo có thể chia cho kích thước patch  $P$ . Từ đây, ảnh sẽ được duỗi ra thành các vectors và ánh xạ tuyến tính tới các vector gồm  $D$  chiều (patch embedding). Trong đó,  $D$  là độ dài ẩn của các lớp trong mạng Transformer khi đi qua từng lớp.

Không giống như đặc trưng được trích xuất bởi các mạng CNN, các mô hình Transformer không có độ lệch quy nạp dành riêng cho hình ảnh và xử lý hình ảnh dưới dạng một chuỗi các patches. Do đó, mô hình dễ dàng chú ý hơn đến toàn bộ hình ảnh hoặc các bản patches độc lập trong từng hình ảnh. Hình 3 thể hiện kiến trúc tổng quan của mạng TrOCR.


Với độ hiệu quả trong các tác vụ ngôn ngữ tự nhiên của các Mask Language Modeling, các tác giả bài báo BEiT:BERT Pre-Training of Image Transformer [4] đề xuất một mô hình Mask Image Modeling cho tiền huấn luyện mạng Transformer với hình ảnh. Khi đó, mỗi hình ảnh sẽ được chuyển đổi thành hai góc nhìn: image patches và visual tokens. Báo cáo thực hiện tokenize ảnh gốc thành visual token thông qua một mạng Variational Auto Encoder (VAE) rồi rạc [5]. Mạng VAE này đã được tiền huấn luyện cho việc sinh hình ảnh từ ảnh gốc, mask ngẫu nhiên các patches của hình ảnh, và khi này mô hình sẽ cố gắng tái tạo các visual tokens dựa trên các visual tokens được tạo ở bước tokenize. Hình 4 biểu diễn tổng quan kiến trúc mạng BEiT.

#### 2) Bộ giải mã.


Kiến trúc bộ giải mã được lấy từ mạng Transformer nguyên bản [6], mạng chồng các lớp giống hệt nhau và có cấu trúc tương tự với mạng mã hóa của chính nó ngoại trừ việc bộ giải mã trên attention của bộ encoder-decoder vào giữa multi-head self attention và mạng feed forward để phân phối sự chú ý khác nhau trên đầu ra của bộ mã hóa. Trong module attention của bộ mã hóa – giải mã, các khóa và giá trị đến từ đầu ra của bộ mã hóa, trong khi các truy vấn đến từ đầu vào của bộ giải mã. Ngoài ra, bộ giải mã sử dụng cơ chế attention masking để ngăn chặn được nhiều thông tin trong quá trình huấn luyện hơn là dự đoán. Thực tế, đầu ra của bộ giải mã sẽ dịch chuyển sang phải một chút so với đầu vào của bộ giải mã, cơ chế attention mask cần đảm bảo đầu ra tại vị trí  $i$  chỉ có thể chú ý đến đầu ra trước đó tại vị trí nhỏ hơn  $i$ .

$$h_i = Proj(Emb(Token_i)) \quad (1)$$

$$\sigma(h_{ij}) = \frac{e^{h_{ij}}}{\sum_{k=1}^V e^{h_{ik}}}, j = 1, 2, \dots, V \quad (2)$$



Hình 3. Tổng quan kiến trúc mạng TrOCR.



Các trạng thái ẩn từ bộ giải mã được ánh xạ bởi một lớp tuyến tính từ kích thước mô hình đến kích thước của bộ từ vựng  $V$ , với xác suất trên toàn bộ từ vựng được tính thông qua một hàm softmax.

Bộ giải mã của mô hình TrOCR được xây dựng dựa trên mạng RoBERTa [7], một nghiên cứu cải tiến từ BERT [8]. Bài báo trên thực hiện đánh giá một cách kĩ lưỡng các siêu trọng số chính trong mô hình BERT và kích thước của tập dữ liệu huấn luyện. Dựa vào BERT, RoBERTa loại bỏ đi quá trình dự đoán câu tiếp theo (next sentence prediction phase) từ BERT và thay đổi các masking ở Mask Language Modeling trong BERT.


### C. MaskOCR

Mô hình MaskOCR lấy kiến trúc bộ encoder-decoder của mô hình transformer cho bài toán nhận dạng văn bản, tiền

huẩn luyện cả bộ encoder và bộ decoder bằng cách sử dụng chiến lược masking (che khuất hình ảnh/văn bản) theo cách tuần tự. Bộ encoder trích xuất một chuỗi các patches biểu diễn của hình ảnh đầu vào, bộ decoder ánh xạ các biểu diễn đó thành văn bản. Hình 5 minh họa kiến trúc mô hình MaskOCR.

#### 1) Bộ mã hóa.

Bộ encoder nhận đầu vào là một hình ảnh  $I \in \mathbb{R}^{3 \times H \times W}$ . Ảnh sau đó được chia theo chiều ngang thành  $M$  patches dọc  $[p_1, p_2, \dots, p_M]$  mỗi patch có kích thước  $H \times W / M$ . Sau đó các patch được làm phẳng bằng ánh xạ tuyến tính để trích xuất các vector biểu diễn và thêm vào các biểu diễn vị trí. Mô hình Vision Transformer, bao gồm nhiều lớp multi-head self-attention và các lớp FFN, được sử dụng làm khung của bộ encoder, với mục tiêu học các biểu diễn ở cấp độ patch,  $F = f_1, f_2, \dots, f_M$  cho hình ảnh văn bản.



Hình 5. Tổng quan kiến trúc mạng MaskOCR.

### 2) Bộ giải mã.

Bộ decoder được xây dựng dựa theo cấu trúc mạng DETR [9], được nghiên cứu cho nhận diện vật thể. Bộ decoder cấu tạo từ một bộ multi-head self-attention, một bộ multi-head cross-attention, và các lớp FFN. Bộ decoder biến đổi biểu diễn đầu vào là các character query  $\mathbf{C} = \mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_N$  thành các biểu diễn đầu ra, sau đó được ánh xạ độc lập thành các ký tự thông qua bộ phân loại tuyến tính. Cấu trúc multi-head self-attention (encoder-decoder attention) lấy key và value là đầu ra của bộ encoder, và query là character query cho lớp decoder đầu tiên. Ngược lại, đối với các lớp decoder sau, đầu vào của query là biểu diễn đầu ra của lớp decoder trước đó.

### 3) Hàm mất mát.

Hàm mất mát: Các ký tự dự đoán được ký hiệu bởi  $\mathbf{y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N]$ . Giả sử  $N$  lớn hơn số ký tự trong hình ảnh văn bản. Xem nhãn là  $\mathbf{Y}^* = [\mathbf{y}_1^*, \mathbf{y}_2^*, \dots, \mathbf{y}_N^*]$  được padding bằng ký tự kết thúc câu  $[EOS]$ . Hàm mất mát được tính bởi công thức như sau:

$$\mathcal{L}(\mathbf{Y}, \mathbf{Y}^*) = \frac{1}{L+1} \sum_{l=1}^{L+1} CE(\mathbf{y}_l, \mathbf{y}_l^*) \quad (3)$$


Trong đó:  $CE(.,.)$  là hàm mất mát cross-entropy.  $L$  là số ký tự đầu vào. Để cân bằng lượng ký tự  $[EOS]$  và các ký tự khác, bài chỉ sử dụng hàm mất mát trên các ký tự cũng như ký tự  $[EOS]$  đầu tiên.

## III. PHƯƠNG PHÁP THỰC HIỆN

### A. Thông tin về bộ dữ liệu.

Bộ dữ liệu được cung cấp bởi cuộc thi SoICT Hackathon 2023 - Vietnamese Handwritten Text Recognition được tổ chức bởi Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội. [Dữ liệu](#) được cung cấp bởi ban tổ chức gồm 2 tập như sau:

- Training data: là tập dữ liệu thật có gắn nhãn, dùng để huấn luyện mô hình. Tập này gồm 103000 ảnh (Gồm 51000 ảnh form, 48000 ảnh wild và 4000 ảnh GAN).
- Public test: Là tập dữ liệu không nhãn sử dụng để đánh giá vòng sơ loại. Tập này gồm 33000 ảnh. (Gồm 17000 ảnh form và 16000 ảnh wild).




Hình 6. Phân bố kích thước ảnh của bộ dữ liệu huấn luyện.

Đầu vào cho mô hình là ảnh thô chưa gắn nhãn. Tập nhãn là các file định dạng \*.txt. Mỗi dòng của tập chứa thông tin tên ảnh và nhãn là văn bản chứa trong ảnh đó theo khuôn dạng như sau: IMAGE\_NAME [tab] GROUND\_TRUTH\_TEXT.

Bộ dữ liệu huấn luyện gồm các ảnh có kích thước chiều dài và chiều rộng phân bố trên hình 6 biểu diễn trực quan hơn về phân bố kích thước ảnh trong bộ dữ liệu huấn luyện.

Với max\_height=378, max\_width=543, min\_height=11, min\_width= 0, mean\_height=72, mean\_width=131.

Biểu diễn một số phân bố chiều dài của văn bản và 10 ký tự xuất hiện nhiều nhất trong các văn bản của bộ dữ liệu như hình 7a và 7b.



(a) Phân bố chiều dài của các văn bản.  
(b) Tần suất xuất hiện ký tự trong tập dữ liệu huấn luyện.

Hình 7. Một số thông tin về nhãn của dữ liệu huấn luyện.

### B. TrOCR.

Trong bài báo Transformer-based OCR with Pre-trained models (TrOCR) [3], nhóm tác giả Microsoft đã đề xuất một phương pháp nhận dạng văn bản end-to-end với hai mô hình đều tận dụng kiến trúc mạng Transformer cho cả 2 bước mã hóa và giải mã với bộ dữ liệu được tiền huấn luyện trước, một dùng để trích xuất đặc trưng từ hình ảnh và một để tạo văn bản ở mức từ. Mô hình TrOCR này tuy đơn giản nhưng mang lại độ hiệu quả cao và có thể được tiền huấn luyện với dữ liệu tổng hợp quy mô lớn và tinh chỉnh với các tập dữ liệu được gắn nhãn bởi con người.

TrOCR được xây dựng dựa trên kiến trúc mạng Transformer bao gồm kiến trúc Transformer sử dụng cho ảnh nhận trích xuất đặc trưng và kiến trúc Transformer cho văn bản. Mô hình TrOCR bao gồm cấu trúc mạng mã hóa – giải mã. Bộ mã hóa được thiết kế nhằm thu được các vector biểu diễn từ các patches hình ảnh và bộ giải mã được dùng để sinh ra chuỗi từ với sự hướng dẫn của các đặc trưng trích xuất từ hình ảnh và các dự đoán trước đó. Các thử nghiệm cho thấy mô hình TrOCR vượt qua các mô hình khác và hiện đang là mô hình tốt nhất trên nhiều tác vụ nhận dạng văn bản bao gồm

văn bản in, văn bản viết tay, và trích xuất văn bản từ hình ảnh cảnh quan môi trường thực tế.

### C. MaskOCR

Có ba pipeline chính trong nhận diện văn bản:

- (i) Pipeline dựa trên từng ký tự xác định và nhận diện từng ký tự sau đó gom chúng thành từ.
- (ii) Pipeline dựa trên từ, thực hiện phân loại ngay từ đầu.
- (iii) Pipeline dựa trên chuỗi, coi việc nhận diện văn bản là vấn đề gắn nhãn chuỗi, và được áp dụng bởi phần lớn các phương pháp học sâu.

Bài báo **MaskOCR: Text Recognition with Masked Encoder-Decoder Pretraining** [10] tuân theo pipeline dựa trên chuỗi và sử dụng một bộ encoder-decoder dạng transformer cho việc nhận diện văn bản. Bộ encoder sử dụng kiến trúc của mô hình Vision Transformer [11], các khối self-attention và các layer FFN để trích xuất biểu diễn của các patches hình ảnh - văn bản. Bộ decoder được cấu tạo từ các khối self-attention, cross-attention và FFN, có nhiệm vụ ánh xạ các biểu diễn patch hình ảnh - văn bản thành từ dự đoán.

Phương pháp MaskOCR tiền huấn luyện cả bộ encoder và bộ decoder bằng cách sử dụng chiến lược masking (che khuất hình ảnh/văn bản) theo cách tuần tự. Bộ encoder được tiền huấn luyện bằng phương pháp học tự giám sát, thông qua việc sử dụng các patches hình ảnh, trong đó, một số patches sẽ bị ẩn đi. Bộ decoder được tiền huấn luyện với phương pháp học có giám sát, trong quá trình học chỉ cập nhật trọng số cho bộ decoder mà không ảnh hưởng đến quá trình decode. Kết quả thực hiện trong bài báo [10] cho thấy phương pháp tiền huấn luyện sử dụng cơ chế masking cho 2 bộ encoder và decoder giúp mô hình học tốt hơn và có hiệu suất cao hơn so với các phương pháp nhận dạng văn bản khác cùng thời điểm.

#### 1) Tiền huấn luyện bộ encoder.

Quá trình tiền huấn luyện bộ encoder được thực hiện theo phương pháp học tự giám sát trên ảnh có một số patch bị ẩn. Cụ

thể tiền huấn luyện bộ encoder cho việc học các biểu diễn của hình ảnh văn bản. Hình 8 dưới đây thể hiện cấu trúc tiền huấn luyện cho bộ encoder.

Theo đó, hình ảnh văn bản đầu vào sẽ được chia theo chiều ngang thành các patch hình ảnh dọc. Một số patch hình ảnh sẽ được chọn ngẫu nhiên để ẩn đi. Các patch hình ảnh còn lại sẽ được đưa vào bộ mã hóa để trích xuất đặc trưng. Sau đó các đặc trưng này được sử dụng để dự đoán lại các đặc trưng của các patch bị ẩn, và được dùng để dự đoán lại chính giá trị pixel của patch đó thông qua một mạng giải mã hồi quy chồng nhau. Mục tiêu của quá trình này là huấn luyện cho bộ encoder có khả năng dự đoán chính xác cả đặc trưng và giá trị pixel của các phần bị che khuất dựa trên phần còn lại của hình ảnh văn bản. Qua đó buộc bộ mã hóa phải học các biểu diễn mang tính ngữ nghĩa cao, có khả năng mã hóa các thông tin quan trọng về hình dạng, ngữ cảnh của các ký tự văn bản.


Hàm mất mát của quá trình tiền huấn luyện bộ encoder kết hợp giữa mất mát dự đoán đặc trưng (representation loss) và mất mát dự đoán pixel (prediction loss).

$$\mathcal{L}_t(\mathbf{T}_m, \mathbf{T}_m^*) + \lambda \mathcal{L}_z(\mathbf{Z}_m, \mathbf{Z}_m^*) \quad (4)$$


#### 2) Tiền huấn luyện bộ decoder.

Trong quá trình tiền huấn luyện bộ decoder, bộ encoder tại giai đoạn sẽ không được cập nhật mà chỉ cập nhật trọng số cho bộ decoder. Do đó chất lượng biểu diễn ngữ nghĩa của hình ảnh văn bản sẽ không bị ảnh hưởng trong quá trình huấn luyện bộ decoder. Ngoài ra loại bỏ các ký tự tự dự đoán trùng lặp, bộ decoder còn có khả năng mô hình hóa ngôn ngữ để cải thiện khả năng nhận dạng văn bản. Hình 9 biểu diễn cấu trúc tiền huấn luyện bộ decoder.

Để tăng cường khả năng mô hình hóa ngôn ngữ, mô hình áp dụng ý tưởng Masked Language Modeling và giới thiệu một phương pháp tiền huấn luyện bộ decoder có sử dụng cơ chế masking. Để huấn luyện, một số ký tự và các patch hình



Hình 8. Cấu trúc tiền huấn luyện bộ encoder.



Hình 9. Cấu trúc tiền huấn luyện bộ decoder.

thể, phương pháp này dựa trên mô hình Context Autoencoder

ảnh tương ứng được chọn ngẫu nhiên để ẩn đi. Các patch còn lại được đưa vào bộ encoder để thu được đặc trưng tương ứng  $F_v$ . Sau đó các biểu diễn có giá trị bằng không  $F_m$  được chèn vào vị trí của các patch bị ẩn. Mô hình kết hợp hai biểu diễn trên  $F = [F_v \ F_m]$  cùng với các vector nhúng vị trí tương ứng làm đầu vào cho bộ decoder để dự đoán văn bản:  $\hat{Y} = [\hat{y}_1 \ \hat{y}_2 \ \dots \ \hat{y}_N]$ .

Hàm mất mát của quá trình tiền huấn luyện bộ decoder như hàm mất mát của BERT và chỉ tính trên các ký tự bị ẩn, với  $L$  và  $n_1, n_2, \dots, n_L$  lần lượt là số lượng và vị trí của các ký tự bị ẩn. Công thức biểu diễn hàm mất mát là:

$$\mathcal{L}(\hat{Y}_l, Y_l^*) = \frac{1}{L} \sum_{l=1}^L CE(y_{n_l}, y_{n_l}^*) \quad (5)$$

Báo cáo cài đặt hàm mất mát chỉ tính trên các ký tự bị ẩn, buộc bộ giải mã phải mô hình hóa ngôn ngữ để đoán ký tự bị thiếu dựa trên ngữ cảnh, qua đó nâng cao khả năng dự đoán ký tự dựa trên bối cảnh của bộ giải mã. Việc tiền huấn luyện này giúp bộ giải mã học được các quy tắc ngôn ngữ từ thông tin tổng hợp, đồng thời tăng cường khả năng giải mã dựa trên ngữ cảnh, góp phần nâng cao hiệu quả nhận dạng văn bản.

#### IV. KẾT QUẢ VÀ ĐÁNH GIÁ

##### A. Thang đo.

Khi tiến hành dán nhãn, xử lý hình ảnh, thiết lập thuật toán,... để hoàn thiện mô hình OCR, các nhà nghiên cứu cần đánh giá xem mô hình này có hoạt động hiệu quả hay không, bằng cách sử dụng các chỉ số tiêu chuẩn. Bài viết này cung cấp thông tin về 2 chỉ số được sử dụng phổ biến, bao gồm Tỷ lệ lỗi ký tự (Character Error Rate – CER) và Tỷ lệ lỗi từ (Word Error Rate – WER). Sử dụng tỷ lệ lỗi để xác định mức độ khác nhau giữa văn bản được trích xuất với OCR và văn bản tham chiếu được dán nhãn thủ công.

Với bộ dữ liệu thực hiện chỉ chứa các từ đơn lẻ nên báo cáo xét trên tỷ lệ lỗi ký tự.

##### 1) Phân loại.

CER có 3 loại lỗi cơ bản cần xem xét:

- Lỗi thay thế (Substitution): các ký tự sai lỗi chính tả.
- Lỗi xoá (Deletion): các ký tự bị mất hoặc bị thiếu.
- Lỗi chèn (Insertion): các ký tự không chính xác.

STEAM STEAM STEAM  
STEAL TEAM STREAM

Substitution Deletion Insertion

Hình 10. Ba nhóm lỗi ký tự cơ bản (nguồn: Toward Data Science).

Vấn đề ở đây là làm thế nào để đo lường mức độ sai lệch giữa 2 chuỗi văn bản. Thông thường chúng ta sử dụng kỹ thuật Khoảng cách Levenshtein (Levenshtein distance). Khoảng cách Levenshtein là một kỹ thuật đo lường sự khác biệt giữa hai chuỗi, thông qua thống kê số lần chỉnh sửa một ký tự/từ tối thiểu (bao gồm chèn, xóa hoặc thay thế) cần thiết để thay đổi một từ thành một từ khác.

##### 2) Công thức tính tỷ lệ lỗi ký tự.

Tính toán chỉ số CER dựa trên kỹ thuật khoảng cách Levenshtein bằng cách đếm số lượng tối thiểu các hoạt động cấp ký tự cần thiết để chuyển đổi văn bản tham chiếu vào thành tệp đầu ra OCR. Công thức tính CER trình bày như sau:

$$CER = \frac{S + D + I}{N} \quad (6)$$

Trong đó: S là số lần thay thế.

D là số lần xóa

I là số lần chèn.

N là tổng số ký tự của văn bản tham chiếu.

Mẫu số N có thể tính theo công thức (6), C là số ký tự đúng.

##### 3) Ý nghĩa.

Tùy thuộc trường hợp sử dụng và điều kiện liên quan, tỷ lệ lỗi ký tự CER được sử dụng để đánh giá mức độ hiệu quả của OCR tương ứng. Các tình huống và độ phức tạp khác nhau (ví dụ: văn bản in so với văn bản viết tay, loại nội dung, v.v.) có thể dẫn đến các hiệu suất OCR khác nhau. Tuy nhiên, chúng ta có thể tham khảo đánh giá độ chính xác của một số tổ chức uy tín tại Úc như sau (đối với văn bản in):


- Độ chính xác OCR tốt: CER 1-2% (tức độ chính xác 98–99%).
- Độ chính xác OCR trung bình: CER 2-10%
- Độ chính xác OCR kém: CER > 10% (tức là độ chính xác dưới 90%)
- Đối với các trường hợp phức tạp liên quan đến văn bản viết tay có nội dung không đồng nhất và xa rời từ vựng (ví dụ: đơn đăng ký), giá trị CER cao khoảng 20% có thể được coi là đạt yêu cầu.

##### B. Kết quả thực hiện.

Nhóm đã thực hiện được việc áp dụng kiến trúc Transformer vào mô hình bộ mã hóa – giải mã sử dụng bước huấn luyện cơ chế masking theo Masking Language Modeling để giải quyết bài toán nhận diện chữ viết tay Tiếng Việt. Kết quả thử nghiệm trên các mô hình được thể hiện ở bảng 1.

Hình 11 thực hiện chạy model nhận diện chữ viết tay với tập dữ liệu training và testing chia với tỉ lệ 95:5.

```
Number of training examples: 97850
Number of validation examples: 5150
pixel_values torch.Size([3, 384, 384])
labels torch.Size([128])
```




Hình 11. Ví dụ một kết quả nhận diện chữ viết tay.

BẢNG I. KẾT QUẢ THỬ NGHIỆM TRÊN CÁC MÔ HÌNH.

| Mô hình | Tỷ lệ lỗi (CER) |
|---------|-----------------|
| TrOCR   | 0.1164          |
| MaskOCR | 0.1378          |


Thực hiện huấn luyện mô hình bằng dữ liệu trong tập OCR Hackathon và kiểm thử trên bộ dữ liệu public\_test\_data để được tỷ lệ sai lỗi ký tự.

Một số kết quả xác định chữ viết tay trên ảnh như hình dưới đây.



Hình 12. Ví dụ kết quả nhận diện chữ viết tay đúng.

Một số trường hợp sai như hình 13 dưới đây.



Hình 13. Ví dụ một số kết quả nhận diện sai chữ.

Nhóm đã thực hiện thành công việc xây dựng model nhận diện chữ viết tay Tiếng Việt với kiến trúc Transformer. Để thuận tiện cho nhiều người sử dụng, nhóm đã thiết kế được giao diện web để dễ dàng tương tác hơn. Hình ảnh giao diện demo ở hình 14.

### C. Đánh giá.

Nhóm đã thành công xây dựng được hai mô hình nhận diện chữ viết tay Tiếng Việt bằng kiến trúc Transformer thuần túy và Transformer cải tiến với quá trình tiền huấn luyện Masked Encoder – Decoder. Các mô hình có độ chính xác tốt trên tác vụ nhận diện chữ viết tay với tỷ lệ lỗi đạt yêu cầu đối với ngưỡng cho phép của một mô hình OCR. Nhóm đã có đóng góp vào bài toán nhận diện chữ viết tay một số giải pháp, nêu ra các vấn đề còn tồn đọng trong tác vụ này, từ đó, xây dựng các hướng giải quyết tối ưu hơn.

Tập huấn luyện có kích thước ảnh khá nhỏ dẫn đến mô hình khá nhạy cảm với sự thay đổi nhỏ của ảnh đầu vào. Trong quá trình thực nghiệm, nhóm cũng đã gặp khó khăn trong việc xử lý hình ảnh chất lượng kém: Mô hình Transformer có thể gặp khó khăn khi xử lý ảnh đầu vào có chất lượng kém, bị mờ, nhiễu hoặc thiếu ánh sáng. Ngoài ra, việc huấn luyện mô hình có kiến trúc hoàn toàn dựa vào mạng Transformer nên gặp nhiều trở ngại về nguồn lực huấn luyện khiến cho mạng chưa hoàn toàn hội tụ trên tập huấn luyện. Vì vậy phương pháp này chưa mang lại kết quả tốt nhất cho việc giải quyết tác vụ nhận diện chữ viết tay.


Một số vấn đề nhóm đã gặp phải trong quá trình thực hiện.

### BẢNG II. MỘT SỐ VẤN ĐỀ TRONG QUÁ TRÌNH THỰC HIỆN VÀ GIẢI PHÁP ĐÃ ĐƯA RA.

| Vấn đề gặp phải                                   | Phương pháp giải quyết                                                                                    |
|---------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| Các mô hình nặng, mất nhiều thời gian huấn luyện. | Sử dụng các mô hình huấn luyện sẵn (pre-trained model), học chuyên tiếp (transfer learning). Sử dụng GPU. |
| Lập trình, lỗi code, xung đột phần mềm, thư viện. | In kết quả ra màn hình, tìm kiếm lỗi trên mạng, cộng đồng lập trình.                                      |
| Tài nguyên phần cứng.                             | Sử dụng các nền tảng miễn phí như Google Colaboratory, Kaggle.                                            |

### TÀI LIỆU THAM KHẢO

- [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. Gomez, { . Kaiser, and I. Polosukhin. Attention is all you need. Advances in neural information processing systems, page 5998–6008. Arxiv:1706.03762, 2017.
- [2] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. CoRR, abs/1512.00567, 2015.
- [3] Minghao Li, Tengchao Lv, Jingye Chen, Lei Cui, Yijuan Lu, Dinei Florencio, Cha Zhang, Zhou-jun Li, and Furu Wei. Trocr: Transformer-based optical character recognition with pre-trained models. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pages 13094–13102, 2023.
- [4] Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. Beit: Bert pre-training of image transformers. arXiv preprint arXiv:2106.08254, 2021.
- [5] Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. Zero-shot text-to-image generation. In International Conference on Machine Learning, pages 8821–8831. PMLR, 2021.
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. Advances in neural information processing systems, 30, 2017. Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.
- [7] Yinhan Liu, Mylène Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692, 2019.
- [8] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. arXiv preprint arXiv:2005.12872, 2020.
- [9] Pengyuan Lyu, Chengquan Zhang, Shanshan Liu, Meina Qiao, Yangliu Xu, Liang Wu, Kun Yao, Junyu Han, Errui Ding, and Jingdong Wang. Maskocr: Text recognition with masked encoder-decoder pretraining. arXiv preprint arXiv:2206.00311, 2022.
- [10] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2021.



Hình 14. Giao diện sử dụng và ảnh mẫu tải lên.